Gustavo P. Gouveia (6482819), Victor Lassance (6431325)

Relatório de Compiladores - Primeira Etapa - Construção de um analisador léxico

#### Gustavo P. Gouveia (6482819), Victor Lassance (6431325)

## Relatório de Compiladores - Primeira Etapa - Construção de um analisador léxico

Texto apresentado à Escola Politécnica da Universidade de São Paulo como requisito para a aprovação na disciplina Linguagens e Compiladores no quinto módulo acadêmico do curso de graduação em Engenharia de Computação, junto ao Departamento de Engenharia de Computação e Sistemas Digitais (PCS).

Universidade de São Paulo Escola Politécnica Engenharia de Computação - Curso Cooperativo

Professor: Ricardo Luis de Azevedo da Rocha

São Paulo 2013

#### Resumo

Este trabalho descreve a concepção e o desenvolvimento de um compilador utilizando a linguagem C. O escopo do compilador se limita a casos mais simples, porém simbólicos, e que servem ao aprendizado do processo de criação e teste de um compilador completo. A estrutura da linguagem escolhida para ser implementada se assemelha a própria estrutura do C, por facilidade de compreensão.

Palavras-chaves: Linguagens, Compiladores, Analisador Léxico.

## Sumário

| Su                                                           | Sumário |          |    |    |     |     |     |     |    |    |     |     |     |    |    |    |    |    |    |    |   |   |   |    |      |    |    |   |   |    |    |   |   |   |   |    |
|--------------------------------------------------------------|---------|----------|----|----|-----|-----|-----|-----|----|----|-----|-----|-----|----|----|----|----|----|----|----|---|---|---|----|------|----|----|---|---|----|----|---|---|---|---|----|
| 1                                                            | Intro   | odução . |    |    |     |     |     |     |    |    |     |     |     | •  |    |    | •  |    |    |    |   |   | • |    |      |    |    |   |   |    |    |   |   |   |   | 4  |
| 2                                                            | Que     | stões .  |    |    |     |     |     |     |    |    |     |     |     |    |    |    | •  |    |    |    |   |   | • |    |      |    |    |   |   |    |    |   |   |   |   | 5  |
|                                                              | 2.1     | Questão  | 1  |    |     |     |     |     |    |    |     |     |     |    |    |    |    |    |    |    |   |   |   |    |      |    |    |   |   |    |    |   |   |   |   | 5  |
|                                                              | 2.2     | Questão  | 2  |    |     |     |     |     |    |    |     |     |     |    |    |    |    |    |    |    |   |   |   |    |      |    |    |   |   |    |    |   |   |   |   | 6  |
|                                                              | 2.3     | Questão  | 3  |    |     |     |     |     |    |    |     |     |     |    |    |    |    |    |    |    |   |   |   |    |      |    |    |   |   |    |    |   |   |   |   | 7  |
|                                                              | 2.4     | Questão  | 4  |    |     |     |     |     |    |    |     |     |     |    |    |    |    |    |    |    |   |   |   |    |      |    |    |   |   |    |    |   |   |   |   | 9  |
|                                                              | 2.5     | Questão  | 5  |    |     |     |     |     |    |    |     |     |     |    |    |    |    |    |    |    |   |   |   |    |      |    |    |   |   |    |    |   |   |   |   | 11 |
|                                                              | 2.6     | Questão  | 6  |    |     |     |     |     |    |    |     |     |     |    |    |    |    |    |    |    |   |   |   |    |      |    |    |   |   |    |    |   |   |   |   | 12 |
|                                                              | 2.7     | Questão  | 7  |    |     |     |     |     |    |    |     |     |     |    |    |    |    |    |    |    |   |   |   |    |      |    |    |   |   |    |    |   |   |   |   | 13 |
|                                                              | 2.8     | Questão  | 8  |    |     |     |     |     |    |    |     |     |     |    |    |    |    |    |    |    |   |   |   |    |      |    |    |   |   |    |    |   |   |   |   | 13 |
|                                                              | 2.9     | Questão  | 9  |    |     |     |     |     |    |    |     |     |     |    |    |    |    |    |    |    |   |   |   |    |      |    |    |   |   |    |    |   |   |   |   | 13 |
|                                                              | 2.10    | Questão  | 10 |    |     |     | •   |     |    |    |     |     |     | •  |    | •  |    |    |    |    | • | • |   |    |      |    |    |   | • |    |    |   | • | • | • | 14 |
| 3                                                            | Con     | clusão . |    |    |     |     |     |     |    |    |     |     | •   | •  |    | •  | •  |    |    | •  |   |   | • |    |      |    |    | - |   |    |    |   |   |   |   | 15 |
| Apêndices 16                                                 |         |          |    |    |     |     |     |     |    |    |     | 16  |     |    |    |    |    |    |    |    |   |   |   |    |      |    |    |   |   |    |    |   |   |   |   |    |
| ΑF                                                           | PÊNE    | DICE A   | Tr | ar | ารต | lut | toı | r c | lo | Δ  | ۱na | ali | isa | d  | or | L  | éx | ic | 0  | •  |   |   | • |    | •    |    |    |   |   |    |    |   |   |   |   | 17 |
| APÊNDICE B Código em C da sub-rotina do Analisador Léxico 19 |         |          |    |    |     |     |     |     |    |    |     |     | 19  |    |    |    |    |    |    |    |   |   |   |    |      |    |    |   |   |    |    |   |   |   |   |    |
| ΑF                                                           | PÊNE    | DICE C   | Cá | ód | igo | Э 6 | em  | 1 ( |    | do | r   | né  | éto | od | 0  | pr | in | ci | рā | al | d | 0 | Α | na | alis | sa | do | r | L | éx | ic | 0 |   |   |   | 29 |

## 1 Introdução

TODO Introdução vlassance

#### 2 Questões

A seguir, seguem as respostas às questões propostas pelo professor.

#### 2.1 Questão 1

Quais são as funções do analisador léxico nos compiladores e interpretadores?

O analisador léxico atua como uma interface entre o reconhecedor sintático, que forma, normalmente, o núcleo do compilador, e o texto de entrada, convertendo a sequência de caracteres de que este se constitui em uma sequência de átomos.

Para a consecução de seus objetivos, o analisador léxico executa usualmente uma série de funções, todas de grande importância como infraestrutura para a operação das partes do compilador mais ligadas à tradução propriamente dita do texto-fonte. As principais funções são listadas abaixo:

- Extração e Classificação de Átomos;
  - Principal funcionalidade do analisador;
  - As classes de átomos mais usuais: identificadores, palavras reservadas, números inteiros sem sinal, números reais, strings, sinais de pontuação e de operação, caracteres especiais, símbolos compostos de dois ou mais caracteres especiais e comentários.
- Eliminação de Delimitadores e Comentários;
- Conversão numérica;
  - Conversão numérica de notações diversas em uma forma interna de representação para manipulação de pelos demais módulos do compilador.
- Tratamento de Identificadores;
  - Tratamento com auxílio de uma tabela de símbolos.
- Identificação de Palavras Reservadas;
  - Verificar se cada identificador reconhecido pertence a um conjunto de identificadores especiais.
- Recuperação de Erros;

- Listagens;
  - Geração de listagens do texto-fonte.
- Geração de Tabelas de Referências Cruzadas;
  - Geração de listagem indicativa dos símbolos encontrados, com menção à localização de todas as suas ocorrências no texto do programa-fonte.
- Definição e Expansão de Macros;
  - Pode ser realizado em um pré-processamento ou no analisador léxico. No caso do analisador, deve-se haver uma comunicação entres os analisadores léxico e sintático.
- Interação com o sistema de arquivos;
- Compilação Condicional;
- Controles de Listagens.
  - São os comandos que permitem ao programador que ligue e desligue opções de listagem, de coleta de símbolos em tabelas de referência cruzadas, de geração, e impressão de tais tabelas, de impressão de tabelas de símbolos do programa compilador, de tabulação e formatação das saídas impressas do programa-fonte.

#### 2.2 Questão 2

Quais as vantagens e desvantagens da implementação do analisador léxico como uma fase separada do processamento da linguagem de programação em relação à sua implementação como sub-rotina que vai extraindo um átomo a cada chamada?

Geralmente, o gargalo encontrado durante a compilação de um programa sem otimização é a leitura de arquivos e a análise léxica. Separando-se o analisador léxico do resto do compilador, é possivel otimizar esse módulo e obter um analisador léxico genérico que serviria a princípio para qualquer linguagem.

A desvantagem de se separar os dois é o desacoplamento da lógica e, por conseguinte, das informações disponíveis ao analizador sintático e semântico, informações estas que podem ser importantes no reconhecimento das classes dos tokens encontrados dependendo da linguagem a ser compilada.

Exemplo: Shell Script - O primeiro **echo** refere-se ao comando echo e o segundo refere-se ao primeiro argumento do comando.

echo echo

1

#### 2.3 Questão 3

Defina formalmente, através de expressões regulares sobre o conjunto de caracteres ASCII, a sintaxe de cada um dos tipos de átomos a serem extraídos do texto-fonte pelo analisador léxico, bem como de cada um dos espaçadores e comentários.

• DELIM: /[{}()\[\];]/

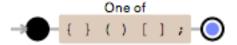


Figura 1 – Expressão Regular DELIM

• SPACE:  $/[ \t\n\v\f] +/$ 

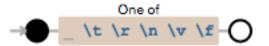


Figura 2 – Expressão Regular SPACE

• COMMENT: /#[^\n]\*/



Figura 3 – Expressão Regular COMMENT

• IDENT: /[a-zA-Z\_][a-zA-Z0-9\_]\*/

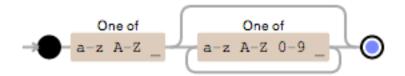


Figura 4 – Expressão Regular IDENT

• INTEGER: /[0-9]+/

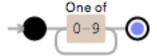


Figura 5 – Expressão Regular INTEGER

• FLOAT: /[0-9]\*\.[0-9]+/

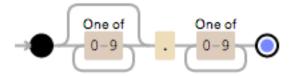


Figura 6 – Expressão Regular FLOAT

• CHAR: /'(?:\\[0abtnvfre\\'"]|[\x20-\x5B\x5D-\x7E])'/

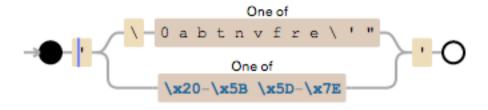


Figura 7 – Expressão Regular CHAR

• STRING: /"(?:\\"|[^"])\*"/

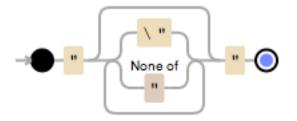


Figura 8 – Expressão Regular STRING

• OPER: /[+-\*/%=!<>][=]?/

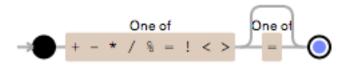


Figura 9 – Expressão Regular OPER

#### 2.4 Questão 4

Converta cada uma das expressões regulares, assim obtidas, em autômatos finitos equivalentes que reconheçam as correspondentes linguagens por elas definidas.

• DELIM: /[{}()\[\];]/

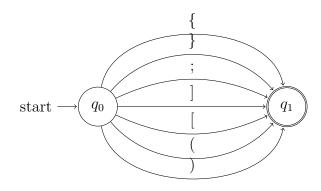


Figura 10 – Autômato finito DELIM

• SPACE: /[ \t\r\n\v\f]+/

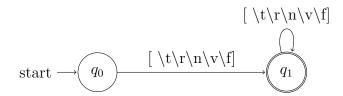


Figura 11 – Autômato finito SPACE

• COMMENT: /#[^\n]\*/

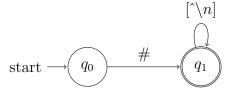


Figura 12 – Autômato finito COMMENT

• IDENT: /[a-zA-Z\_][a-zA-Z0-9\_]\*/

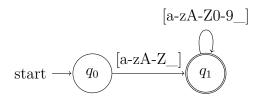


Figura 13 – Autômato finito IDENT

• INTEGER: /[0-9]+/

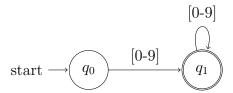


Figura 14 – Autômato finito INTEGER

• FLOAT: /[0-9]\*\.[0-9]+/

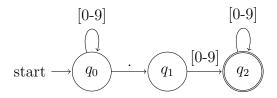


Figura 15 – Autômato finito FLOAT

Capítulo 2. Questões

• CHAR: /'(?:\\[0abtnvfre\\'"]|[\x20-\x5B\x5D-\x7E])'/

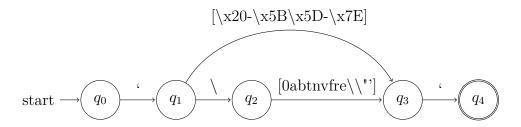


Figura 16 – Autômato finito CHAR

• STRING: /"(?:\\"|[^"])\*"/

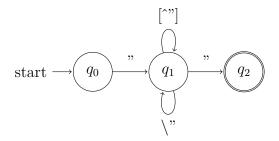


Figura 17 – Autômato finito STRING

• OPER: /[\+\-\\*\/%=!<>][=]?/

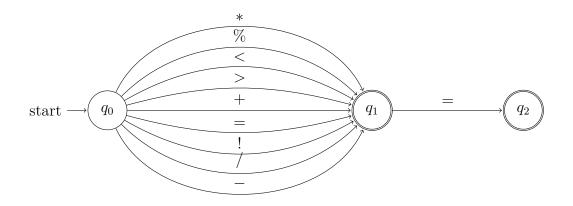
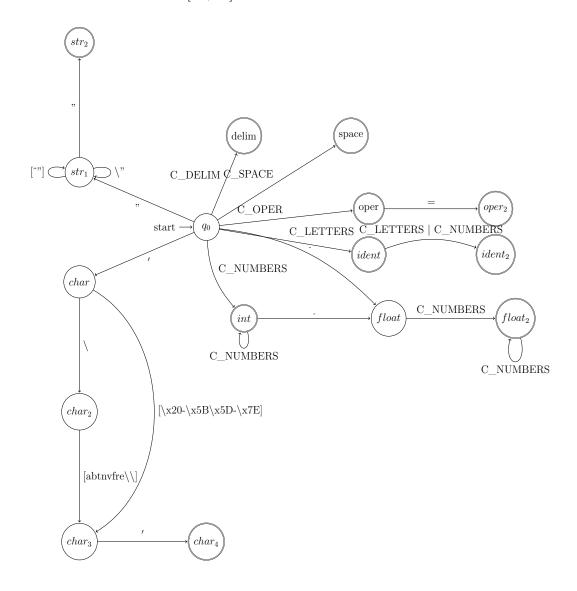


Figura 18 – Autômato finito OPER

#### 2.5 Questão 5

Crie um autômato único que aceite todas essas linguagens a partir de um mesmo estado inicial, mas que apresente um estado final diferenciado para cada uma delas. Capítulo 2. Questões 12

- $C_DELIM = [91, 93, 123, 125, 40, 41, 59]$
- $C\_SPACE = [32, 9, 10, 11, 12, 13]$
- $C_{OPER} = [42, 37, 60, 62, 43, 61, 33, 47, 45]$
- $C_{LETTERS} = [65, ..., 90, 97, ..., 122, 95]$
- $C_NUMBERS = [48, 57]$



#### 2.6 Questão 6

Transforme o autômato assim obtido em um transdutor, que emita como saída o átomo encontrado ao abandonar cada um dos estados finais para iniciar o reconhecimento de mais um átomo do texto.

O transdutor obtido a partir da transformação da questão 5 pode ser encontrado no apêndice A.

Capítulo 2. Questões 13

#### 2.7 Questão 7

Converta o transdutor assim obtido em uma sub-rotina, escrita na linguagem de programação de sua preferência.

A sub-rotina escrita e testada pode ser encontrada no apêndice B. O código está comentado e seu funcionamento é explicado na questão 9.

#### 2.8 Questão 8

Crie um programa principal que chame repetidamente a sub-rotina assim construída, e a aplique sobre um arquivo do tipo texto contendo o textofonte a ser analisado. Após cada chamada, esse programa principal deve imprimir as duas componentes do átomo extraído (o tipo e o valor do átomo encontrado).

O programa principal que utiliza as sub-rotinas pertencentes ao analisador léxico pode ser encontrada no apêndice C. O código está comentado e seu funcionamento é explicado na questão 9.

#### 2.9 Questão 9

Relate detalhadamente o funcionamento do analisador léxico assim construído, incluindo no relatório: descrição teórica do programa; descrição da sua estrutura; descrição de seu funcionamento; descrição dos testes realizados e das saídas obtidas.

O analisador léxico lê um arquivo de configuração da máquina de estados (transdutor) o mesmo pode ser comparado à seguinte regex:

$$(.)([^{1}*)^{1}*(A-Za-z]+(:? [0-9]+)?)$$

Cada linha possui uma lista de caracteres delimitados por um caractere especial (por exemplo '+' ou '#') e dois identificadores que designam os estados inicial e final da transição. O caractere @ designa todas as transições, este é usado principalmente para encaminhar qualquer aceitação final de um sub-autômato ao estado QO, para então ser tratado normalmente.

Ex:

| + abc defghijklm nop qrstuv xywz + | Q0 | IDENT |
|------------------------------------|----|-------|
| +ABCDEFGHIJKLMNOPQRSTUVXYWZ+       | Q0 | IDENT |
| + +                                | O0 | IDENT |

Este exemplo vai reconhecer todos os caracteres a-b e A-B mais o underscore (\_) como transições do estado Q0 e IDENT.

Após a leitura do arquivo de configuração (e de um arquivo com *keywords*). Faz-se a leitura do arquivo fonte, por meio do transdutor, percorre-se o arquivo fonte token a token. Uma função next\_useful\_token oferece o não retorno dos tokens de espaço, tal qual a quebra de linha e espaços normais. O motor do lex também substitui classes IDENT em RESERVED se a palavra se encontra na lista de identificadores reservados.

Uma hashtable está sendo desenvolvida e será integrada nas próximas versões do compilador.

#### 2.10 Questão 10

Explique como enriquecer esse analisador léxico com um expansor de macros do tipo #DEFINE, não paramétrico nem recursivo, mas que permita a qualquer macro chamar outras macros, de forma não cíclica.

Uma forma de permitir a utilização de macros seria o de realizar o pré-processamento, substituindo no código todas as macros pelos seus valores. Caso isso não seja desejado, também é possível acrescentar o tratamento de macros no analisador léxico, como explicitado na questão.

A maneira mais prática seria de se armazenar todas as macros em um vetor ou hash table, de forma similar a como é feito com as palavras reservadas. Ao se encontrar um identificador de macro, deve-se adicionar a um buffer o conteúdo da macro e deve-se processar o buffer até que o mesmo termine, antes de retornar a leitura do arquivo. Caso haja um identificador de macro dentro da definição de uma macro, pode-se substituir o identificador pela sua definição dentro do buffer que já está sendo lido, pra facilitar a lógica.

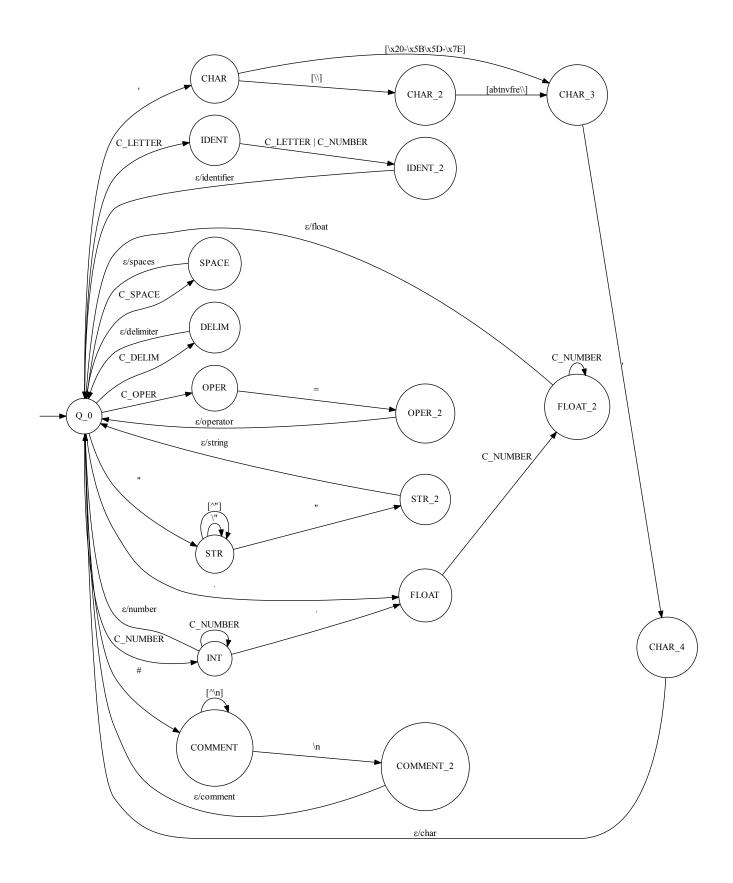
Uma possível solução para não tratar macros como casos únicos de utilização de buffers de leitura, pode-se ler um conjunto de caracteres a cada vez do arquivo e sempre armazenar em um buffer, lendo o arquivo novamente somente quando o buffer estiver vazio. Dessa forma, a macro nada mais será que uma substituição de um identificador por uma definição.

### 3 Conclusão

TODO Conclusão vlassance



## APÊNDICE A – Transdutor do Analisador Léxico



## APÊNDICE B – Código em C da sub-rotina do Analisador Léxico

#### lex.h

```
#ifndef LEX PCS2056
1
2
  # define LEX_PCS2056
3
4
  # define MAX_NUM_TRANSITIONS 50
6 # define MAX_NUM_STATES 50
7 | # define MAXLENGTHSTATESTR 50
8 # define ENCODING_MAX_CHAR_NUM 256
  # define MAX_SIZE_OF_A_TOKEN 2048
10 |# define MAX_NUMBER_OF_KEYWORDS 256
11
12
   typedef struct State {
       char* name;
13
14
       char* class name;
       int number_of_transitions;
15
16
       long* masks [MAX_NUM_TRANSITIONS];
17
       struct State* transitions[MAX_NUM_TRANSITIONS];
18
   } State;
19
20
   typedef struct Token {
       long line;
21
22
       long column;
23
       long size;
24
       char* class_name;
25
       State* origin_state;
       char* str;
26
27
   } Token;
28
29
   int _number_of_states;
30
31
   State* state_table [MAX_NUM_STATES];
32 | char buff_token [MAX_SIZE_OF_A_TOKEN];
```

```
long buff_token_end;
33
34
35
36
   char* vkeywords [MAX_NUMBER_OF_KEYWORDS];
37
   long vkeywords_size;
38
39
   void initialize_lex();
   int next_useful_token(FILE* f, Token** t);
40
   void print token(Token* t);
41
42
43 #endif
```

#### lex.c

```
1 #include <stdio.h>
2 #include <string.h>
3 #include <stdlib.h>
4 #include "lex.h"
5
6
   /**
7
    * Printing procedures
8
    */
   void print_state(State* st) {
10
        int i;
        long maskterm, maskdepl, cod;
11
12
        long masktermsize = sizeof(long) * 8;
        printf("[\%s] \setminus n", st->name);
13
        for (i = 0; i < st->number_of_transitions; i++) {
14
            printf("");
15
            for (cod = 0; cod < ENCODING_MAX_CHAR_NUM; cod++) {
16
                maskterm = cod / masktermsize;
17
                maskdepl = cod % masktermsize;
18
                 printf (
19
20
                     "%c",
                     (st->masks[i][maskterm] & (1L<<maskdepl))?'1':'0
21
22
                 );
23
24
            printf(" \setminus n_{\sqcup}");
            for (cod = 0; cod < ENCODING_MAX_CHAR_NUM; cod++) {
25
```

```
maskterm = cod / masktermsize;
26
27
                 maskdepl = cod % masktermsize;
                 if (st->masks[i][maskterm] & (1L<<maskdepl)) {
28
                      printf("%ld", cod);
29
                 }
30
31
             printf("_{\square}->_{\square}\%s\n", st->transitions[i]->name);
32
        }
33
   }
34
35
   void print_all_states() {
36
37
        int i;
        for (i = 0; i < _number_of_states; i++) {
38
39
            print_state(state_table[i]);
        }
40
   }
41
42
43
   void print_token(Token* t) {
44
        printf(">_{\sqcup}[\%s]", t->class\_name);
        printf(")>> \%s << ", t >> str);
45
46
        printf(" at (\%ld, \%ld), with size (\%ld n", t-> line, t-> column)
           , t\rightarrow size);
   }
47
48
49
   /**
50
    * This is a very dummy implementation for a search 'n 'insert
        operation on
    * a 'set'.
51
52
    */
   void state_from_name(char* statename, State** st) {
53
54
        int i, size;
55
        char* pch;
        // find a state that matchs, if so, return it within st
56
        for (i = 0; i < \underline{number\_of\_states}; i++) {
57
             if (strcmp(statename, state\_table[i]->name) == 0)  {
58
59
                 *st = state_table[i];
60
                 return;
61
            }
62
        }
```

```
// malloc size of State, here we do not care about freeing
63
           states,
64
       // since the lex parser will run until the life span of the
           compiler run,
65
       // the memory will be used until the end. No need to free it
66
       state_table[_number_of_states] = malloc(sizeof(State));
67
       state_table[_number_of_states]->name = malloc(
            sizeof(char) * (strlen(statename) + 1) // +1 for the \0
68
       );
69
70
       strcpy(state_table[_number_of_states]->name, statename);
71
       // we should cut the '_' they are just different variations
72
           of the same class
73
       pch = strrchr(statename, '_');
74
       if (!pch) {
75
            size = strlen(statename);
76
       } else {
            size = pch - statename;
77
78
79
       state_table[_number_of_states]->class_name = malloc(
            sizeof(char) * (size + 1)
80
81
82
       strncpy(state_table[_number_of_states]->class_name,
          statename, size);
83
       *st = state_table[_number_of_states++];
   }
84
85
   void add_mask_to_state(State** from, State** to, long* mask) {
86
       (*from)->masks[(*from)->number_of_transitions] = mask;
87
       (*from) \rightarrow transitions[(*from) \rightarrow number_of_transitions++] = *to
88
   }
89
90
   int lex_parser_read_char(FILE* f) {
91
       char from name [MAXLENGTHSTATESTR];
92
93
       char toname [MAXLENGTHSTATESTR];
94
       long *mask;
95
       char sep;
```

```
96
        char c;
97
        long cod;
        long maskterm, maskdepl;
98
99
        int i;
100
        State *from;
101
        State *to;
102
        long mask term size = size of (long) * 8; // number of byts on a
103
             lonq
104
        if (fscanf(f, " \ \%c", \&sep) = EOF \mid sep = EOF) {
105
106
             return 0;
107
108
        // complete mask of chars
109
        mask = malloc (ENCODING MAX CHAR NUM / (8));
110
        for (i = 0; i < ENCODING_MAX_CHAR_NUM / (8 * sizeof(long));
           i++) {
             // operator that means "all transitions" (in order to
111
                simulate the 'transductor')
             mask[i] = (sep = '@')?(-1L):(0L);
112
113
        }
        // for each char different from sep, insert a transition
114
        while (fscanf(f, "%c", &c) && c != sep && c != EOF) {
115
116
             cod = (long) c;
117
             maskterm = cod / masktermsize;
             maskdepl = cod % masktermsize;
118
             mask[maskterm] |= (1L<<maskdepl);
119
120
121
        // origin state
        fscanf(f, "\%s", fromname);
122
        state_from_name(fromname, &from);
123
124
        // destiny state
125
        fscanf(f, "\\%s", toname);
126
        state from name (toname, &to);
127
        add_mask_to_state(&from, &to, mask);
128
        return 1;
129
    }
130
131
```

```
void find_next_state_from_char(char c, State** from, State** to)
132
         long mask term size = size of (long) * 8; // number of byts on a
133
             long
         long cod, maskterm, maskdepl;
134
135
         int i;
136
         (*to) = NULL;
137
         cod = (long) c;
138
         maskterm = cod / masktermsize;
139
         maskdepl = cod % masktermsize;
140
         for (i = 0; i < (*from)->number_of_transitions; i++) {
141
             // search for mathing out states.
             if ((*from)->masks[i][maskterm] & (1L<<maskdepl)) {
142
143
                  (*to) = (*from) \rightarrow transitions[i];
144
                  break;
145
             }
         }
146
147
    }
148
    int next useful token(FILE* f, Token** t) {
149
150
         int res, i;
151
152
         do {
153
             res = next\_token(f, t);
154
         } while(
             *\,t\  \, !=\  \, \mathrm{NULL}\,\,\&\&\,\,
155
156
             res &&
             strcmp((*t)->origin_state->class_name, "SPACE") == 0
157
             // ignore SPACES
158
         );
159
160
161
         if (! res | | *t == NULL) \{
162
             return res; // if error or no token, return it to the
                 caller.
         }
163
164
165
         if (strcmp((*t)->origin\_state->class\_name, "IDENT") == 0) {
166
             for (i = 0; i < vkeywords\_size; i++) {
```

```
167
                 // dummy search for keywords, this should become a
                    hashtable
168
                 // for the next project
                 if (strcmp((*t)->str, vkeywords[i]) == 0) {
169
170
                     break;
                 }
171
            }
172
173
            if (i == vkeywords_size) {
174
                 (*t)->class name = malloc(6 * sizeof(char));
                 strcpy((*t)->class_name, "IDENT");
175
            } else {
176
                 (*t)->class_name = malloc(9 * sizeof(char));
177
                 // name it RESERVED in case it is
178
179
                 strcpy((*t)->class_name, "RESERVED");
            }
180
        } else {
181
            (*t)->class_name = malloc(
182
183
                 (strlen((*t)->origin\_state->class\_name) + 1) *
                    sizeof(char)
184
            );
            strcpy((*t)->class_name, (*t)->origin_state->class_name)
185
186
187
        // to be sure that this will not be used
        (*t)->origin_state = NULL;
188
189
        return res;
190
    }
191
192
    int next_token(FILE* f, Token** t) {
193
        static State *current_state = NULL;
194
        static long cline = 1;
195
        static long ccolumn = 0;
196
        static long line = 1;
197
        static long column = 1;
198
        static char tmpend = 1;
199
        char next_c;
200
201
        State* next_state;
202
        // tmpend is static, if i read something that was
```

```
203
        // EOF in the last step, this is the end and I should set t
            to null
204
        if (tmpend = EOF) 
205
            (*t) = NULL;
206
            return 1;
207
        }
208
209
        if (current_state == NULL) {
            // current_state is null, it means that this is
210
                initialization
            // change it to Q0 and set the buffer to ""
211
            state_from_name("Q0", &current_state);
212
            buff\_token\_end = 0;
213
214
            buff\_token[0] = '\0';
        }
215
216
217
        do {
            // get char, lookahead
218
219
            tmpend = fscanf(f, "%c", &next_c);
            if (next_c = '\n') { // column management
220
221
                 cline++;
222
                 ccolumn = 0;
223
            } else {
224
                 ccolumn++;
225
            }
226
227
            next_state = NULL;
228
            // let's see if there's a defined next state
229
            find_next_state_from_char(next_c, &current_state, &
                next_state);
            // if next state is Q0, it means that this is
230
                acceptation,
            // we should stop, go to QO and reevaluate the
231
                transition.
232
            // Since the transductor have an empty transition to Q0
                , we are
233
                 obligated to do so.
234
             if (next_state != NULL && strcmp(next_state->name, "Q0")
                == 0){
```

```
235
                  (*t) = malloc(sizeof(Token));
236
                  (*t)->str = malloc(sizeof(char) * (strlen(buff_token)
                     + 1L);
                  strcpy((*t)->str, buff_token);
237
                  (*t)->line = line;
238
239
                  (*t)->column = column;
240
                  (*t)->origin_state = current_state;
241
                  (*t)->size = strlen(buff_token);
242
                  find_next_state_from_char(next_c, &next_state, &
                     current_state);
243
                  column = ccolumn;
244
                  line = cline;
                  // memorize next_c
245
246
                  buff\_token[0] = next\_c;
247
                  buff token [1] = ' \setminus 0';
                  buff\_token\_end = 1;
248
249
                  // no current_state but no end of file either, this
                     seams to be a
250
                  // problem.
                  if (current state == NULL && tmpend != EOF) {
251
252
                       fprintf(
253
                           stderr,
                           "buff_token_(1): <%s>, _ error_at_line_%ld_
254
                               \operatorname{column}_{\square}\%\operatorname{ld}_{n},
255
                           buff_token,
256
                           cline,
257
                           ccolumn
258
                       );
259
                       return 0;
                  }
260
                  return 1;
261
262
             } else {
263
                  buff_token[buff_token_end++] = next_c;
                  buff_token[buff_token_end] = '\0';
264
             }
265
             // no next state, raise error.
266
267
              if (next_state == NULL) {
268
                 fprintf(
269
                      stderr,
```

```
270
                      "buff_token_(2): < %s >, error_at_line_%ld_column_s
                        %ld n',
                     buff_token,
271
272
                      cline,
273
                     ccolumn
274
                 );
275
                 return 0;
276
277
             current state = next state;
        \} while (tmpend != EOF);
278
279
        (*t) = NULL;
280
        return 1;
281
    }
282
283
    void initialize lex() {
284
        FILE *lex_file , *keywords_file;
285
        vkeywords\_size = 0;
        _number_of_states = 0;
286
287
        lex file = fopen("./languagefiles/lang.lex", "r");
288
        keywords_file = fopen("./languagefiles/keywords.txt", "r");
289
290
291
        // parse the configuration file
292
        while (lex_parser_read_char(lex_file)) {
293
        }
        // read keywords file
294
        while (fscanf(keywords_file, "\\%s", buff_token) != EOF) {
295
             vkeywords[vkeywords_size] = malloc(sizeof(char) * (
296
                strlen(buff_token) + 1L));
             strcpy(vkeywords[vkeywords_size++], buff_token);
297
        }
298
299
```

# APÊNDICE C – Código em C do método principal do Analisador Léxico

```
#include <stdio.h>
   #include "lex.h"
2
3
   int main(int argc, char *argv[]) {
4
5
        FILE *input_file;
        Token* tk;
 6
 7
8
        if (argc \ll 1)
             fprintf(stderr, "Usage:\n");
9
             fprintf(stderr, "_{\sqcup\sqcup}\%s_{\sqcup}<input_{\sqcup}file>\n", argv[0]);
10
11
             return 1;
        }
12
13
14
        initialize_lex();
15
        input_file = fopen(argv[1], "r");
16
17
        while (next_useful_token(input_file, &tk) && tk != NULL) {
18
           print_token(tk);
19
        }
20
21
22
        if (tk == NULL)
23
             return 0;
24
        return 1;
25
   }
```